

Count-Min Sketch y CountSketch en ventanas deslizantes para detección de ataques

Grupo de trabajo

Tópicos en Grandes Volúmenes de Datos
Tarea 1, 2026

Resumen

Se implementaron Count-Min Sketch (CMS) y CountSketch (CS) sobre una ventana deslizante de 60 s, actualizada cada 10 s mediante seis subventanas. Se evaluaron frecuencias, detección de heavy hitters y cambios de frecuencia para un DDoS por IP destino y un scan por IP origen. En todas las configuraciones, el conteo total de paquetes y la decisión de heavy hitter coincidieron con la referencia exacta. El error de frecuencia disminuyó al aumentar el ancho; el MRE en las ventanas afectadas fue menor que 2.34 % en todos los casos.

1. Método y datos

La ventana activa es $W_j = (\tau_j - 60, \tau_j]$ y se divide en seis subventanas de 10 s. Se conserva un sketch por subventana y el agregado A_j . Al rotar el anillo se resta el sketch expirado y se actualizan simultáneamente el nuevo sub-sketch y A_j . La alineación usa intervalos $(t_0 + (q - 1)10, t_0 + q10]$; el total N_j se mantiene con seis contadores escalares. El umbral de heavy hitter es $T_j = \lceil 0.01N_j \rceil$.

Se usó la traza MAWI samplepoint-F del 1 de enero de 2017, disponible en <http://mawi.nezu.wide.ad.jp/mawi/samplepoint-F/2017/201701011400.pcap.gz>. Los ataques se generaron con semilla 42, duración de 30 s e inicio a los 300 s: DDoS de 50 000 paquetes/s contra 222.160.209.129 (4 000 fuentes) y scan de 8 000 paquetes/s desde 198.18.0.7. La clave consultada fue destino para DDoS y origen para scan. Se utilizaron $d = 5$ y $w \in \{256, 1024, 4096\}$.

El MRE se calculó sólo en J : evaluaciones posteriores al inicio mientras queden paquetes inyectados en la ventana activa, y con frecuencia exacta positiva. Para estos parámetros, J tiene ocho evaluaciones (ventanas 25–32). Las figuras de frecuencia muestran el contexto solicitado, desde 60 s antes del inicio hasta 60 s después del fin del ataque. Los CSV por configuración conservan el error de cada ventana y las comparaciones contra la referencia exacta.

2. Frecuencia y detección

La actualización por linealidad evita reconstruir desde cero los 60 s de tráfico al avanzar la ventana. La rotación toca $O(dw)$ contadores, independiente del número de paquetes que sigan dentro de la ventana; cada paquete entrante actualiza el sketch agregado y el sub-sketch correspondiente.

Cuadro 1: Resultados de frecuencia y detección. Memoria persistente: ocho tablas de contadores más seis escalares. Durante la estimación de Δf se reserva una tabla temporal adicional.

Ataque	Sketch	w	MRE (%)	Memoria (KB)	Desacuerdos HH	Latencia (s)
SCAN	CMS	256	2.3324	40.05	0	10
SCAN	CMS	1024	0.4117	160.05	0	10
SCAN	CMS	4096	0.0882	640.05	0	10
SCAN	CS	256	0.5855	40.05	0	10
SCAN	CS	1024	0.0078	160.05	0	10
SCAN	CS	4096	0.0037	640.05	0	10
DDOS	CMS	256	0.7044	40.05	0	10
DDOS	CMS	1024	0.1528	160.05	0	10
DDOS	CMS	4096	0.0373	640.05	0	10
DDOS	CS	256	0.1230	40.05	0	10
DDOS	CS	1024	0.0010	160.05	0	10
DDOS	CS	4096	0.0009	640.05	0	10

En las 84 ventanas de cada configuración se verificó N_j contra `exact_hh`; no hubo desalineaciones ni desacuerdos de decisión HH. Las doce configuraciones detectaron en la ventana 25, la misma que la referencia exacta. La latencia observada fue 10 s, con resolución temporal igual al paso de evaluación. En general el MRE cae al aumentar w , pues disminuyen las colisiones. En estos datos CS tuvo menor MRE que CMS para los tres anchos de ambos ataques; esto es un resultado experimental de una semilla, no una garantía para cualquier ejecución.

El scan queda concentrado en una IP de origen y no presenta tráfico de fondo para esa clave; el DDoS agrupa el ataque por la IP destino de la víctima. La diferencia de clave representa la estructura de cada ataque. La tasa DDoS utilizada es mayor, por lo que la frecuencia de ataque domina con claridad el ruido relativo de colisiones.




Figura 1: Frecuencia exacta y estimada alrededor de cada ataque. Se muestran CMS y CS para los tres anchos.

3. Cambios de frecuencia

El cambio $\Delta f_j(x) = f_j(x) - f_{j-1}(x)$ indica tanto la magnitud como el sentido de la variación; permite observar el ingreso y salida del ataque, que una frecuencia de ventana aislada no muestra. En el salto de entrada, el cambio exacto máximo fue 80 000 paquetes para SCAN y 500 000 para DDoS; las salidas producen los cambios negativos correspondientes.

CS aplica a diferencias firmadas su estimador habitual, la mediana de $s_r(x)C[r, h_r(x)]$. CMS usa la mediana de los contadores de diferencia (CMS-mediana), no el mínimo: el vector diferencial puede contener negativos y pierde la propiedad de frecuencias no negativas que justifica la sobreestimación de CMS. Esta variante es experimental y no conserva las garantías estándar de CMS.

Cuadro 2: MAE de Δf en el contexto del ataque, en paquetes.

Ataque	Estimador	$w = 256$	$w = 1024$	$w = 4096$
SCAN	CMS-mediana	38.06	12.75	3.38
SCAN	CS	26.94	11.50	3.06
DDoS	CMS-mediana	90.19	9.12	5.56
DDoS	CS	74.44	11.88	4.69

El error diferencial disminuye claramente al aumentar el ancho, aunque CS no es mejor en cada celda: con DDoS y $w = 1024$, CMS-mediana obtuvo menor MAE. El resultado refuerza que la comparación es empírica y que la mediana de CMS sobre datos firmados no hereda las garantías del CMS estándar.




Figura 2: Cambios exactos y estimados. CMS-mediana y CountSketch se comparan en las seis configuraciones.

4. Validación limpia y conclusiones

En la traza sin ataques se consultó 203.143.43.244 por origen. El error absoluto medio (paquetes) y el MRE fueron: CMS, 3061.54 y 0.2898 % para $w = 256$, 669.42 y 0.0634 % para $w = 1024$, 136.76 y 0.0129 % para $w = 4096$; CS, 963.82 y 0.0912 %, 138.51 y 0.0131 %, y 13.81 y 0.0013 %, respectivamente. Esta comprobación usa una clave durante todas las ventanas; los resultados detallados de ataques se conservan por ventana en `csv/`.

La linealidad permite mantener la ventana con trabajo de rotación proporcional al tamaño del sketch, no al volumen de tráfico histórico retenido. Ambos estimadores detectaron los dos ataques en la misma evaluación que el conteo exacto. Aumentar w redujo el error de frecuencia y, en general, el de los cambios. CMS es apropiado para frecuencias no negativas y tiende a sobreestimar; CS admite signos y su estimación es insesgada en el modelo usual, pero sus errores observados dependen de la semilla y pueden no ser monótonos.